

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Ahmad Dhani Alfawwas (24031554096)
Anggota 1	Maria Agatha Metri Tetrajati (24031554189)
Anggota 2	Tara Tabriza Rachman (24031554107)
URL Github	https://github.com/apa-nyak/final-project-ml

Informasi Umum Proyek

Judul	Implementasi dan Analisis Komparatif MobileNetV3 dan DenseNet121 untuk Klasifikasi Penyakit Daun Padi
Topik	Pangan
Pilihan Rumusan Masalah	1.2 Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan
Revisi?	Ya / Tidak

Pendahuluan


Latar belakang
(≥ 250 kata)

Sektor pertanian, Khususnya komoditas padi, memegang peranan yang cukup krusial dalam menjaga stabilitas ketahanan pangan nasional di Indonesia [1]. Beras sebagai makanan pokok bagi mayoritas penduduk di Indonesia, fluktuasi produksi padi akan berdampak langsung pada stabilitas ekonomi dan sosial. Namun, salah satu tantangan dan ancaman terbesar yang secara konsisten membayangi produktivitas hasil panen adalah serangan patogen yang memicu penyakit pada daun padi, seperti Bacterial Leaf Blight, Brown Spot, hingga Leaf Smut. Keterlambatan dalam mengidentifikasi anomali pada fase awal infeksi sering kali berujung pada meluasnya area penyebaran penyakit, yang pada akhirnya menyebabkan gagal panen dan kerugian finansial masif bagi para petani [1], [2].

Hingga saat ini, proses monitoring kesehatan tanaman di Indonesia masih dihadapkan pada kesulitan dalam proses transformasi digital. Mayoritas petani masih sangat bergantung pada metode konvensional, yakni melalui pengamatan visual secara manual di lapangan. Pendekatan ini memiliki keterbatasan fundamental karena sangat bergantung pada jam terbang dan pengalaman subjektif petani, memakan waktu yang relatif lama, serta berisiko tinggi menghasilkan diagnosis yang keliru, terutama mengingat gejala awal dari berbagai penyakit daun memiliki kemiripan tekstur dan warna [3]. Permasalahan ini sejalan dengan isu strategis "Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan", yang menyoroti masih rendahnya penetrasi teknologi digital dan kecerdasan buatan (Artificial Intelligence) pada tataran akar rumput sektor pertanian.

Di sisi lain, peningkatan kebutuhan pangan nasional menuntut adanya sistem pertanian yang lebih efisien, cepat, dan berbasis presisi (Smart Farming). Oleh karena itu, penerapan teknologi Computer Vision berbasis Deep Learning menjadi salah satu solusi paling menjanjikan untuk mengotomatisasi proses identifikasi


	penyakit tanaman secara akurat [2]. Sayangnya, implementasi teknologi ini belum sepenuhnya dapat diselesaikan karena terbentur oleh berbagai tantangan teknis dan infrastruktur di lapangan. Tantangan pertama adalah kondisi lingkungan akuisisi citra yang sangat bervariasi. Citra daun yang diambil oleh petani sering kali memiliki perbedaan intensitas pencahayaan, bayangan, sudut pengambilan gambar, serta kualitas resolusi kamera yang beragam [3]. Tantangan kedua terletak pada karakteristik dataset medis pertanian itu sendiri, yang secara alami selalu tidak seimbang (extreme class imbalance). Penyakit endemik tertentu sering kali mendominasi populasi data, yang jika tidak ditangani dengan tepat, akan menyebabkan model pembelajaran mesin mengalami bias dan kehilangan kemampuannya dalam mendeteksi patogen minoritas yang tidak kalah berbahayanya [3], [4]. Tantangan terakhir dan yang paling krusial adalah rendahnya literasi teknologi serta keterbatasan akses perangkat keras bagi para petani. Arsitektur Convolutional Neural Network (CNN) konvensional umumnya memiliki puluhan juta parameter yang membutuhkan daya komputasi tingkat tinggi, sehingga sangat sulit untuk diintegrasikan secara real-time ke dalam perangkat berspesifikasi rendah (low-resource devices) seperti ponsel pintar standar yang dimiliki petani [5]. Berdasarkan urgensi dan kompleksitas tantangan tersebut, diperlukan sebuah penelitian lebih lanjut mengenai implementasi pipeline klasifikasi citra daun padi yang komprehensif. Penelitian ini harus mampu menjembatani kesenjangan tersebut melalui rekayasa pra pemrosesan citra yang adaptif, mitigasi ketidakseimbangan data secara algoritmik, serta pemanfaatan arsitektur Transfer Learning yang sangat efisien dan ringan [4], [5]. Pendekatan ini diharapkan tidak hanya menghasilkan model dengan presisi yang tinggi, tetapi juga aplikatif dan inklusif untuk mendorong percepatan adopsi Smart Farming di Indonesia.
Rumusan masalah dan tujuan	Rumusan Masalah: 1. Bagaimana pengaruh penerapan rekayasa fitur spasial (CLAHE dan Sharpening) serta pemotongan adaptif (Adaptive Cropping) terhadap kemampuan ekstraksi fitur model CNN? 2. Bagaimana efektivitas metode algoritmik Class Weights dalam memitigasi efek overfitting pada kelas mayoritas (Brown Spot) tanpa melakukan resampling fisik? 3. Arsitektur manakah antara CNN-MLP baseline, DenseNet121, dan MobileNet yang paling optimal dalam memberikan keseimbangan antara akurasi prediksi kelas minoritas dan efisiensi komputasi waktu inferensi? Tujuan Penelitian: Mengembangkan sistem klasifikasi penyakit daun padi yang efisien dan tangguh terhadap imbalanced data menggunakan arsitektur Transfer Learning ringan, yang dioptimalkan melalui pipeline preprocessing adaptif dan pembobotan kelas, sehingga layak diimplementasikan pada perangkat komputasi terbatas.
Metodologi	
Ringkasan dataset	Dataset final yang digunakan dalam penelitian ini merupakan hasil ekstraksi dari anotasi deteksi objek (YOLO format). Dataset terdiri dari citra irisan patogen daun padi yang telah melalui tahap penyaringan area dan perluasan dinamis. Distribusi akhir terdiri dari 5 kelas klasifikasi utama: BacterialLeafBlight, BrownSpot, Healthy

	(Daun Sehat), LeafSmut, dan kelas agregasi OtherDisease (gabungan dari penyakit minoritas). Seluruh citra telah diseragamkan ke dalam dimensi 224x224 piksel dengan 3 saluran warna (RGB) dan disimpan dalam struktur direktori siap latih.
Alur penelitian	 <pre> graph LR 1((1 Dataset Citra Daun Padi + Label YOLO)) --> 2((2 Cropping Berdasarkan YOLO)) 2 --> 3a((3 Resize Citra 224x224)) 3a --> 3b((3 Peningkatan Kualitas Citra (CLAHE + Sharpening))) 3b --> 4((4 Data Augmentation & Normalisasi)) 4 --> 5((5 Split Train & Validation)) 5 --> 6((6 DataLoader PyTorch)) 6 --> 7((7 Penanganan Imbalance (Class Weight))) 7 --> 8((8 Pelatihan Model (MobileNetV3 dan DenseNet121))) 8 --> 9((9 Validasi dan Evaluasi)) 9 --> 10((10 Eksternal Test)) 10 --> 11((11 Analisis Hasil)) </pre> <i>Gambar 1. Flowchart</i> Berikan ilustrasi (flowchart atau BPMN chart) yang meringkas proses pengolahan data untuk menyelesaikan permasalahan yang diangkat. Tuliskan deskripsi lengkap pada tiap langkah. Adapun tahapan penelitian yang dilakukan pada penelitian ini meliputi proses pengumpulan dataset, preprocessing dan rekayasa fitur, pelatihan model deep learning, hingga evaluasi performa model. Hal ini sesuai dengan rangkaian proses pada Gambar 1. Flowchart, adapun penjelasan tiap langkahnya yaitu. 1. Dataset Citra Daun Padi + Label YOLO Tahap awal penelitian dimulai dengan pengumpulan dataset citra daun padi yang mencakup beberapa kelas penyakit dan kondisi daun sehat. Dataset yang digunakan memiliki file anotasi berformat YOLO yang berisi koordinat lokasi penyakit pada daun padi. Anotasi ini digunakan sebagai acuan untuk menentukan area penyakit yang akan diproses pada tahap selanjutnya. 2. Cropping Berdasarkan YOLO Tahap berikutnya dilakukan proses cropping menggunakan koordinat anotasi YOLO untuk memotong area penyakit dari citra asli. Hal ini dilakukan karena dalam satu gambar dapat memuat lebih dari satu objek penyakit dengan label yang berbeda. Melalui proses cropping, setiap hasil potongan citra hanya akan merepresentasikan satu kelas penyakit saja. Sehingga model akan lebih fokus dalam mempelajari karakteristik visual penyakit daun padi. 3. Resize Citra 224x224 Setelah proses cropping dilakukan, seluruh citra hasil cropping akan diubah ukurannya menjadi 224x224 piksel. Resize dilakukan agar seluruh data yang input memiliki ukuran yang sama dan sesuai dengan kebutuhan arsitektur model deep learning yang digunakan. 4. Peningkatan Kualitas Citra (CLAHE + Sharpening) Tahap ini bertujuan untuk meningkatkan kualitas visual citra sebelum masuk ke proses pelatihan model. Metode CLAHE (Contrast Limited Adaptive Histogram Equalization) digunakan untuk meningkatkan kontras lokal citra sehingga detail tekstur, pola bercak, dan area lesi penyakit dapat terlihat lebih jelas. Selain itu diterapkan pula proses sharpening untuk mempertajam

	<i>detail tepi dan tekstur penyakit sehingga karakteristik visual penyakit lebih mudah dipelajari oleh model.</i> 5. <i>Data Augmentation dan Normalisasi</i> Untuk meningkatkan variasi data pelatihan dan kemampuan generalisasi model, dilakukan proses augmentasi data menggunakan horizontal flip, random rotation, dan color jitter. Augmentasi ini membantu model mengenali objek penyakit dalam berbagai kondisi pencahayaan dan orientasi citra. Setelah augmentasi selesai maka citra akan dilakukan normalisasi menggunakan mean dan standard deviation dari ImageNet agar distribusi nilai pixel menjadi lebih beragam. 6. <i>Split Train dan Validation</i> Dataset yang telah diproses kemudian dibagi menjadi dua bagian yaitu data pelatihan (training set) sebesar 80% dan data validasi (validation set) sebesar 20%. Pembagian dataset dilakukan untuk melatih model sekaligus mengevaluasi performanya selama proses training berlangsung. 7. <i>DataLoader PyTorch</i> Data train dan validasi dimuat menggunakan DataLoader PyTorch agar proses pengambilan data dapat dilakukan secara batch selama pelatihan model berlangsung, dimana pada penelitian ini digunakan batch size sebesar 32 citra. Penggunaan DataLoader membantu meningkatkan efisiensi proses training terutama pada penggunaan GPU. 8. <i>Penanganan Imbalance Data (Class Weight)</i> Karena jumlah data antar kelas tidak seimbang, digunakan pendekatan class weight pada fungsi loss (CrossEntropyLoss). Pendekatan ini memberikan bobot lebih besar pada kelas minoritas sehingga model tidak cenderung bias terhadap kelas mayoritas selama proses pelatihan berlangsung. 9. <i>Pelatihan Model (MobileNetV3, DenseNet121)</i> Tahap pelatihan dilakukan menggunakan dua arsitektur deep learning yaitu MobileNetV3 dan DenseNet121. Kedua model ini menggunakan pendekatan transfer learning berbasis pretrained ImageNet yang dimana proses pelatihan dilakukan selama beberapa epoch menggunakan optimizer Adam dengan learning rate sebesar 0.0001. 10. <i>Validasi dan Evaluasi</i> Model yang telah dilatih kemudian dievaluasi menggunakan data evaluasi untuk mengukur performa model pada setiap epoch. Evaluasi dilakukan menggunakan beberapa metrik klasifikasi seperti accuracy, precision, recall, dan F1-score. Selain itu juga digunakan confusion matrix untuk mengetahui pola kesalahan klasifikasi pada masing-masing kelas penyakit daun padi. 11. <i>Eksternal Test</i> Setelah proses validasi model selesai dilakukan, tahap selanjutnya adalah pengujian eksternal menggunakan dataset baru yang belum pernah digunakan pada proses pelatihan sebelumnya. Model yang digunakan merupakan model terbaik dari hasil yang didapatkan setelah proses evaluasi. Pengujian eksternal ini dilakukan untuk mengukur kemampuan generalisasi model dalam mengenali penyakit daun padi pada data yang benar-benar berbeda, sehingga dapat dipastikan bahwa model benar-benar memiliki kemampuan klasifikasi dan generalisasi terbaik. 12. <i>Analisis Hasil</i> Tahap akhir dilakukan analisis terhadap hasil evaluasi model dalam mengklasifikasikan penyakit daun padi. Analisis dilakukan dengan membandingkan performa ketiga model berdasarkan metrik evaluasi yang diperoleh, hal ini dilakukan untuk melihat model mana yang memiliki kemampuan paling baik dalam mengklasifikasi penyakit daun padi.
--	--

Proses wrangling	<i>Proses wrangling data pada penelitian ini difokuskan pada transformasi format dataset dari ranah Deteksi Objek (berbasis anotasi YOLO) menjadi dataset murni untuk Klasifikasi Citra (Image Classification). Transformasi ini memerlukan presisi tinggi agar konteks visual dari patogen tidak hilang saat gambar dipotong. Tahapan wrangling yang dieksekusi meliputi:</i> <i>1. Denormalisasi Sistem Koordinat (YOLO ke Piksel): Titik koordinat patogen yang semula tersimpan dalam skala persentase 0 hingga 1 (format YOLO) dikonversi menjadi nilai matriks piksel absolut. Transformasi ini mengembalikan nilai titik tengah (x_center, y_center) beserta dimensi lebar dan tinggi menjadi koordinat sudut batas yang pasti (X_min, Y_min, X_max, Y_max).</i> <i>2. Penyaringan Anomali (Noise Reduction): Sistem menghitung persentase rasio luas kotak patogen (bounding box) terhadap luas total citra daun. Algoritma diinstruksikan untuk mengabaikan (melakukan skip) anotasi yang rasionya sangat mikroskopis (< 0.0005). Langkah preventif ini memastikan model klasifikasi tidak mempelajari noise visual atau kesalahan pelabelan.</i> <i>3. Perluasan Bingkai Dinamis (Adaptive Expand Ratio): Ini merupakan inti dari proses ekstraksi fitur spasial. Pemotongan tidak dilakukan tepat pada garis batas patogen, melainkan diberikan padding tambahan secara adaptif. Jika bercak patogen sangat kecil, bingkai diperluas secara masif hingga 3.0 kali lipat. Sebaliknya, jika patogen sudah mendominasi area daun, perluasan dibatasi pada 0.2 kali lipat. Mekanisme ini dirancang untuk mempertahankan sedikit jaringan daun sehat di sekitar lesi sebagai konteks pembandingan visual bagi model CNN.</i> <i>4. Validasi Dimensi (Clamping) dan Eksekusi: Menyesuaikan koordinat hasil perluasan agar tidak melewati batas resolusi maksimal citra asli. Matriks citra kemudian dipotong (slicing) dan dikategorikan ke dalam struktur direktori kelas secara otomatis.</i>
Proses rekayasa fitur	<i>Pada penelitian ini dilakukan beberapa tahapan rekayasa fitur untuk meningkatkan kualitas representasi visual penyakit daun padi sebelum masuk ke tahap pelatihan model. Tahap pertama dilakukan melalui proses cropping berbasis anotasi YOLO. Cropping diterapkan secara selektif dengan tetap mempertahankan sebagian konteks visual di sekitar area penyakit, namun menghilangkan bagian citra yang tidak relevan [6]. Pendekatan ini bertujuan agar model dapat lebih fokus dalam mempelajari karakteristik visual penyakit, dimana yang sebelumnya dataset bersifat multi-objek diubah menjadi citra klasifikasi tunggal. Selanjutnya, seluruh citra akan diubah ukuran menjadi 224x224 piksel agar memiliki dimensi input seragam dan sesuai kebutuhan.</i> <i>Selanjutnya dilakukan tahap peningkatan kualitas citra menggunakan metode Contrast Limited Adaptive Histogram Equalization (CLAHE). Pendekatan ini bertujuan untuk meningkatkan akurasi dan efektivitas deteksi penyakit pada gambar daun tanaman padi dengan mengatasi tantangan terkait kontras [7]. Dengan peningkatan kontras tersebut, fitur-fitur visual seperti pola bercak penyakit, degradasi warna daun dan tekstur kerusakan jaringan menjadi lebih mudah dipelajari oleh model. Selain peningkatan kontras, dilakukan juga proses sharpening menggunakan kernel fitur untuk mempertajam detail tepi dan tekstur pada area penyakit daun padi. Tahapan ini bertujuan untuk membantu model dalam mengenali detail visual penyakit secara lebih spesifik, terutama pada citra yang memiliki kualitas struktur kurang tajam. Setelah proses tersebut, maka dilakukan tahapan augmentasi data untuk meningkatkan variasi data pelatihan.</i>

	<i>Augmentasi dilakukan menggunakan beberapa transformasi citra seperti horizontal flip, random rotation, dan color jitter. Tujuan dari proses ini adalah untuk menghindari overfitting pada model juga agar model dapat mengenali citra dengan berbagai sudut pandang [8]. Selain itu dilakukan pula proses normalisasi citra menggunakan parameter mean dan standard deviation dari ImageNet. Normalisasi bertujuan untuk menstandarkan distribusi nilai pixel sehingga proses pelatihan model menjadi lebih stabil dan konvergen lebih cepat. Setelah seluruh tahapan rekayasa fitur selesai dilakukan, proses ekstraksi fitur dilakukan secara otomatis oleh arsitektur MobileNetV3 dan DenseNet121 melalui convolution layer yang dimilikinya. Pada tahap ini model akan mempelajari berbagai fitur visual kompleks seperti tekstur, pola bercak, bentuk lesi, distribusi warna, dan karakteristik spasial penyakit daun padi untuk mendukung proses klasifikasi secara optimal.</i>
Temuan	<i>Berdasarkan keseluruhan proses pengolahan data dan pelatihan model yang telah dilakukan, diperoleh beberapa temuan penting terkait klasifikasi penyakit daun padi menggunakan pendekatan deep learning. Proses preprocessing dan rekayasa fitur seperti cropping berbasis YOLO, CLAHE, sharpening, augmentasi data, dan normalisasi terbukti membantu meningkatkan kualitas representasi visual citra sehingga model dapat mempelajari karakteristik penyakit daun padi dengan lebih baik. Selain itu, selama proses penelitian juga ditemukan bahwa distribusi dataset tidak seimbang, dimana beberapa kelas memiliki jumlah data yang jauh lebih banyak dibandingkan kelas lainnya. Kondisi ini berpotensi menyebabkan model lebih dominan mempelajari kelas mayoritas, oleh karenanya diterapkan penanganan imbalance menggunakan class weight agar proses pelatihan model menjadi lebih seimbang.</i> <i>Selain itu ditemukan pula bahwa proses cropping menghasilkan beberapa citra yang berasal dari gambar sumber yang sama. Kondisi ini berpotensi menyebabkan model mengenali pola visual tertentu dari gambar asli sehingga meningkatkan kemungkinan terjadinya overfitting maupun data leakage apabila proses pembagian dataset tidak dilakukan secara tepat. Sehingga pada penelitian ini dilakukan dua tahapan pengujian, yaitu data internal dan eksternal. Pada tahap pengujian internal, performa kedua model yang digunakan menunjukkan hasil yang relatif mirip dan sangat tinggi. Oleh karena itu dilakukan pengujian eksternal menggunakan dataset baru yang belum pernah digunakan sebelumnya untuk memastikan kemampuan generalisasi model secara lebih realistis. Pengujian eksternal dilakukan untuk mengetahui apakah model benar-benar mampu mengenali penyakit daun padi pada data baru atau hanya mempelajari pola tertentu dari data pelatihan.</i>
Hasil dan Pembahasan	
Hasil eksplorasi data	



Gambar 2. Distribusi Dataset

Dataset RICE leaf Diseases memiliki karakteristik khusus yang perlu diperhatikan sebelum masuk ke dalam proses pelatihan model. Pada data latih (train) terdapat sebanyak 6.935 citra dengan anotasi penyakit daun padi yang terbagi ke dalam 9 kelas yaitu BacterialLeafBlight, BrownSpot, Healthy, Hispa, LeafBlast, LeafScald, LeafSmut, NarrowBrownLeafSpot, dan NeckBlast. Pada dataset asli, satu citra tidak selalu hanya merepresentasikan satu objek penyakit. Namun dalam satu gambar dapat ditemukan beberapa area infeksi sekaligus, oleh karena itu dilakukan proses cropping berdasarkan koordinat bounding box dari label YOLO Detection untuk memisahkan setiap area penyakit menjadi citra individual. Proses ini bertujuan untuk mengubah dataset deteksi objek menjadi dataset klasifikasi citra sehingga model dapat lebih fokus dalam mempelajari karakteristik visual dari masing-masing penyakit.

Setelah dilakukan proses cropping menggunakan kombinasi file label dan citra asli, jumlah dataset meningkat karena satu gambar dapat menghasilkan lebih dari satu hasil potongan. Distribusi jumlah citra masing-masing kelas ditunjukkan pada gambar diatas, dimana dataset ini menunjukkan adanya ketidakseimbangan kelas yang cukup tinggi. Kelas BrownSpot mendominasi jumlah data hasil cropping, sedangkan beberapa kelas lain memiliki jumlah citra yang sangat sedikit. Bahkan kelas NeckBlast tidak menghasilkan citra setelah proses preprocessing karena kemungkinan anotasi tidak memenuhi kriteria cropping. Kondisi ini berpotensi menyebabkan model lebih dominan mempelajari pola dari kelas mayoritas dibandingkan kelas minoritas.

Dari sisi kelengkapan informasi, dataset ini bukan merupakan data sparse karena setiap sampel memiliki informasi visual dan anotasi spasial yang jelas. Namun pada dataset ini memiliki variasi distribusi fitur yang tinggi akibat perbedaan jumlah anotasi antar kelas. Sedangkan pada sisi outlier, tidak ditemukan adanya nilai ekstrem numerik karena dataset berupa citra. Tetapi terdapat kemungkinan adanya outlier visual seperti ukuran lesi yang sangat kecil, jumlah objek penyakit yang terlalu banyak dalam satu gambar, atau variasi pencahayaan dan sudut pengambilan gambar. Oleh karena itu, dilakukan tahap preprocessing berupa adaptive cropping dan penyaringan objek berukuran sangat kecil agar data yang digunakan dalam proses klasifikasi menjadi lebih stabil dan representatif.

	 <i>Gambar 3. Perbandingan Gambar Awal dan Hasil Preprocess</i> <i>Hasil preprocessing menunjukkan bahwa teknik CLAHE dan sharpening berhasil meningkatkan kontras serta ketajaman citra. Area lesi penyakit menjadi lebih mudah dibedakan dari jaringan daun sehat, sedangkan tekstur permukaan daun tampak lebih jelas. Peningkatan kualitas visual ini diharapkan membantu model dalam mengekstraksi fitur-fitur penting yang berkaitan dengan karakteristik penyakit daun padi.</i>
Hasil eksperimen	1. <i>Pemisahan Data (Split Data)</i> Agar memastikan model dapat dievaluasi secara objektif dan terhindar dari bias memori (overfitting), dataset keseluruhan yang terdiri dari 5 kelas (Bacterial Leaf Blight, Brown Spot, Healthy, Leaf Smut, Other Disease) dibagi menggunakan skema Hold-Out Validation. Pembagian dilakukan secara acak terstruktur dengan rasio 80:20 menggunakan fungsi <code>random_split</code> dan penetapan seed generator (42) guna menjaga reproduktibilitas eksperimen. Proses ini menghasilkan 14.949 citra sebagai Data Latih (Train) yang digunakan model untuk belajar, dan 3.624 citra sebagai Data Validasi (Val) yang diisolasi ketat untuk menguji kemampuan generalisasi model pada yang belum pernah dilihat sebelumnya. Kedua himpunan data ini kemudian dimuat ke dalam Data Loader dengan ukuran batch sebesar 32. 2. <i>Pelatihan Model (Model Training)</i> Pada penelitian ini mengimplementasikan arsitektur Transfer Learning MobileNetV3-Large, Dense yang telah dilatih sebelumnya dengan bobot ImageNet (<code>pretrained=True</code>). Modifikasi arsitektur dilakukan pada lapisan pengklasifikasi akhir (<code>classifier</code>) agar secara spesifik menghasilkan 5 neuron output yang merepresentasikan jumlah kelas penyakit pada daun padi. Karena adanya ketidakseimbangan data kelas yang ekstrem pada data latih, perhitungan Class Weights sebagai penanganan Imbalanced diterapkan sebelum proses pelatihan dimulai. Nilai bobot penalti ini secara langsung diinjeksikan ke dalam fungsi objektif CrossEntropyLoss. Pelatihan ini dijalankan selama 15 epoch menggunakan optimisator Adam dengan laju pembelajaran yang sangat kecil (0.0001) untuk memastikan model memperbarui bobot secara perlahan dan tidak merusak fitur pra-latih (<code>pretrained features</code>). Selama iterasi berlangsung, sistem secara otomatis mengevaluasi akurasi pada Data Validasi di setiap akhir epoch dan hanya


menyimpan bobot arsitektur terbaik ketika terjadi peningkatan metrik performa (Model Checkpointing).

3. Evaluasi Model Internal

a. MobileNetV3

Tabel 1. Metrik Evaluasi Model MobileNetV3

	<i>precision</i>	<i>recall</i>	<i>f1-score</i>	<i>support</i>
BacterialLeafBlight	0.96	1.00	0.98	310
BrownSpot	1.00	0.99	1.00	2228
Healthy	0.94	1.00	0.97	16
LeafSmut	1.00	0.99	0.99	1051
OtherDisease	0.61	1.00	0.76	19
accuracy			0.99	3.624
macro avg	0.90	1.00	0.94	3.624
weighted avg	0.99	0.99	0.99	3.624



Gambar 4. Confusion Matrix Model MobileNetV3


Desain Pelatihan yang dijelaskan diatas berkaitan langsung dengan pencapaian hasil yang sangat mengesankan pada saat evaluasi. Berdasarkan tes yang dilakukan dengan 3.624 Data Validasi, MobileNet berhasil mendapatkan akurasi keseluruhan sebesar 99%. Keberhasilan metode penambahan bobot kelas ke dalam CrossEntropyLoss selama pelatihan terlihat dari hasil laporan

klasifikasi dan matriks kebingungan. Alih-alih mengalami masalah akurasi yang yang berpihak pada kelas yang lebih banyak, model ini dituntut untuk fokus pada kelas yang lebih sedikit. Ini terlihat dari metrik Recall yang mencapai nilai sempurna 1.00 (100%) untuk kelas *BacterialLeafBlight* (310 gambar), *Healthy* (16 gambar), dan kategori agregasi *OtherDisease* (19 gambar), tanpa ada satu pun gambar dari kelas-kelas tersebut yang salah dikategorikan sebagai *False Negatives*. Secara keseluruhan, kombinasi antara arsitektur *MobileNetV3* yang efisien dalam pengolahan data dan taktik penentuan bobot yang tepat berhasil menciptakan sistem yang kuat dan sangat akurat untuk mendeteksi penyakit pada daun padi.

b. DenseNet121

Tabel 2. Metrik Evaluasi Model DenseNet121

	precision	recall	f1-score	support
<i>BacterialLeafBlight</i>	0.97	0.98	0.97	310
<i>BrownSpot</i>	1.00	1.00	1.00	2228
<i>Healthy</i>	1.00	1.00	1.00	16
<i>LeafSmut</i>	0.99	0.99	0.99	1051
<i>OtherDisease</i>	0.67	0.84	0.74	19
accuracy			0.99	3.624
macro avg	0.92	0.96	0.94	3.624
weighted avg	0.99	0.99	0.99	3.624



Gambar 5. Confusion Matrix Model DenseNet121

Sebagai struktur Transfer Learning sekunder yang dianalisis dalam studi ini, DenseNet121 menunjukkan keahlian luar biasa dalam mengekstrak fitur. Melalui pengujian pada dataset validasi yang mencakup 3.624 gambar, model ini berhasil mencapai akurasi keseluruhan sebesar 99%. Keberhasilan ini disokong oleh desain konektivitas yang padat, di mana setiap lapisan mengakses informasi dari semua lapisan sebelumnya, sehingga aliran data spasial dan gradien optimal selama sesi pelatihan.

Pendalaman lebih lanjut pada Laporan Klasifikasi dan Matriks Kebingungan mengungkapkan karakteristik unik dari model ini. DenseNet121 terbukti sangat kuat dalam menghadapi kelas mayoritas, terbukti dengan kemampuannya untuk memprediksi kelas BrownSpot dengan presisi dan recall mencapai 1.00 (100%), serta dengan tepat mengidentifikais 2.218 dan 2.228 gambar pengujian. Model ini juga menunjukkan sensitivitas penuh pada kategori daun sehat (Healthy), dengan rasio True Positive mencapai 16/16 gambar. Walaupun kinerja keseluruhan sangat memuaskan, analisis kritis terhadap kelas minoritas menunjukkan adanya sedikit bias yang tersisa (Accuracy Paradox). Pada kelas BacterialLeafBlight, ditemukan sedikit kesalahan di mana 5 gambar salah dikategorikan seagai LeafSmut dan 2 sebagai BrownSpot (mendapatkan Recall 0.98). Begitu juga, untuk kategori agregasi OtherDisease, model menemui tantangan dalam membedakan fitur dengan 3 gambar yang “tertegun”(dikenali sebagai BrownSpot), yang mengakibatkan penurunan nilai Recall untuk kategori tersebut menjadi 0.84. hal ini menunjukkan bahwa meskipun bobot kelas telah diterapkan, kompleksitas parameter DenseNet121 masih berpotensi sedikit condong kepada pola visual unggulan dari kelas mayoritas ketika dihadapkan pada contoh yang kurang jelas.

4. Evaluasi Dataset Eksternal

Karena hasil dari evaluasi internal dari data split menghasilkan hasil yang sempurna, maka untuk menguji kesempurnaan itu kami lakukan eksternal tes, berikut hasil evaluasinya:


a. MobileNetV3

Tabel 3. Classification Report Eksternal Test MobileNetV3

	<i>precision</i>	<i>recall</i>	<i>f1-score</i>	<i>support</i>
BacterialLeafBlight	0.26	0.82	0.40	371
BrownSpot	0.68	0.16	0.26	637
Healthy	0.31	0.83	0.45	175
LeafSmut	0.38	0.86	0.52	77
OtherDisease	0.00	0.00	0.00	700
accuracy			0.31	1960
macro avg	0.33	0.53	0.33	1960

weighted avg 0.31 0.31 0.22 1960

Model menunjukkan kemampuan yang cukup baik dalam mengenali pola beberapa kelas tertentu, ditandai dengan nilai recall yang tinggi pada *BacterialLeafBlight* (0,82), *Healthy* (0,83), dan *LeafSmut* (0,86). Akan tetapi nilai precision pada kelas-kelas tersebut relatif rendah, yang berarti model sering memberikan prediksi yang salah meskipun berhasil menemukan sebagian besar sampel yang benar. Selain itu, model gagal mengenali kelas *OtherDisease* dengan nilai precision, recall, dan *F1-score* sebesar 0,00. Hal ini menunjukkan bahwa kelas *OtherDisease* memiliki karakteristik visual yang jauh lebih beragam dibandingkan kelas lain sehingga sulit dipelajari oleh model.



Gambar 6. Confussion Matrix Eksternal Test MobileNetV3

Berdasarkan confusion matrix, MobileNetV3 masih mampu mengenali kelas *BacterialLeafBlight*, *Healthy*, dan *LeafSmut* dengan cukup baik. Hal ini terlihat dari jumlah prediksi benar yang relatif tinggi pada ketiga kelas tersebut, yaitu masing-masing 304, 146, dan 66 citra.

Namun, model mengalami kesulitan dalam membedakan kelas *BrownSpot* dan *OtherDisease*. Dari 637 citra *BrownSpot*, hanya 101 citra yang berhasil diklasifikasikan dengan benar, sedangkan sebagian besar salah diprediksi sebagai *BacterialLeafBlight* dan *Healthy*. Selain itu, model gagal mengenali kelas *OtherDisease* karena tidak ada satupun dari 700 citra yang diprediksi sebagai *OtherDisease*. Sebagian besar citra pada kelas ini justru diklasifikasikan sebagai *BacterialLeafBlight*. Temuan ini menunjukkan bahwa meskipun model memperoleh akurasi sangat tinggi pada validasi internal, kemampuan generalisasinya terhadap data eksternal masih rendah akibat perbedaan distribusi data antara dataset pelatihan dan dataset pengujian.

b. DenseNet121


Tabel 4. Confussion Matrix Eksternal Test DenseNet121

precision *recall* *f1-score* *support*

BacterialLeafBlight	30	89	44	371
BrownSpot	67	38	48	637
Healthy	40	81	54	175
LeafSmut	58	92	71	77
OtherDisease	1.00	0.01	0.01	700
accuracy			40	1960
macro avg	59	60	44	1960
weighted avg	69	40	32	1960

DenseNet121 memperoleh akurasi 40%, lebih tinggi dibanding MobileNetV3 yang sebelumnya memperoleh sekitar 31%. Nilai macro F1-score sebesar 0,44 juga menunjukkan bahwa DenseNet121 memiliki kemampuan generalisasi yang lebih baik pada data baru dibandingkan MobileNetV3.

Jika dilihat per kelas, performa terbaik terdapat pada LeafSmut dengan F1-score sebesar 0,71 dan recall 0,92, yang menunjukkan bahwa sebagian besar citra LeafSmut berhasil dikenali dengan benar. Kelas Healthy juga menunjukkan hasil yang cukup baik dengan F1-score 0,54, sedangkan BrownSpot dan BacterialLeafBlight masih sering tertukar satu sama lain sehingga menghasilkan F1-score yang lebih rendah, yaitu masing-masing 0,48 dan 0,44.



Gambar 7. Confussion Matrix Eksternal Test DenseNet121

Berdasarkan confusion matrix DenseNet121, model menunjukkan performa yang lebih baik dibanding MobileNetV3 pada sebagian besar kelas. Kelas BacterialLeafBlight berhasil dikenali dengan sangat baik, dengan 331 dari 371 citra diklasifikasikan secara benar. Kelas LeafSmut juga memiliki performa tinggi dengan 71 dari 77

	<i>citra berhasil diprediksi dengan tepat. Selain itu, kelas Healthy menunjukkan hasil yang cukup baik dengan 142 dari 175 citra berhasil dikenali.</i> <i>Meskipun demikian, model masih mengalami kesulitan pada kelas BrownSpot dan OtherDisease. Dari 637 citra BrownSpot, hanya 240 citra yang berhasil dikenali dengan benar, sementara sebagian besar salah diklasifikasikan sebagai BacterialLeafBlight (265 citra). Sedangkan OtherDisease hanya dikenal 5 dari 700. Temuan ini menunjukkan bahwa DenseNet121 memiliki kemampuan generalisasi yang lebih baik dibanding MobileNetV3, namun masih mengalami kesulitan dalam membedakan kelas yang memiliki karakteristik visual beragam seperti OtherDisease.</i>
Kesimpulan dan Saran	
Kesimpulan	<i>Penelitian ini berhasil mengembangkan sistem klasifikasi penyakit daun padi menggunakan pendekatan Transfer Learning dengan arsitektur MobileNetV3 dan DenseNet121 yang didukung oleh teknik Adaptive Cropping, CLAHE, dan Sharpening. Hasil evaluasi internal menunjukkan performa yang sangat tinggi dengan akurasi mencapai sekitar 99% pada kedua model. Selain itu, penerapan Class Weights terbukti mampu membantu model mempelajari kelas minoritas tanpa perlu melakukan resampling data.</i> <i>Namun, hasil pengujian menggunakan dataset eksternal menunjukkan penurunan performa yang cukup signifikan, dengan akurasi MobileNetV3 sebesar 31% dan DenseNet121 sebesar 40%. Temuan ini menunjukkan adanya perbedaan distribusi data (domain shift) antara data pelatihan dan data eksternal sehingga kemampuan generalisasi model masih perlu ditingkatkan dan dievaluasi. Meskipun demikian, DenseNet121 menunjukkan performa klasifikasi yang lebih baik pada data eksternal, sedangkan MobileNetV3 tetap unggul dari sisi efisiensi komputasi sehingga lebih sesuai untuk implementasi pada perangkat dengan sumber daya terbatas.</i> <i>Penelitian ini berkontribusi dalam penyelesaian masalah deteksi penyakit daun padi dengan menunjukkan bahwa kombinasi Adaptive Cropping, CLAHE, Sharpening, dan Class Weights mampu membantu model CNN mempelajari karakteristik penyakit secara lebih efektif meskipun dataset mengalami ketidakseimbangan kelas. Selain itu, penelitian ini menemukan bahwa akurasi tinggi pada data validasi internal belum tentu mencerminkan performa yang sama pada data dunia nyata, sehingga pengujian menggunakan dataset eksternal menjadi langkah penting dalam evaluasi model.</i> <i>Bagi masyarakat, khususnya petani dan penyuluh pertanian, temuan ini menunjukkan bahwa teknologi klasifikasi citra berbasis kecerdasan buatan memiliki potensi untuk digunakan sebagai alat bantu identifikasi awal penyakit daun padi secara cepat dan otomatis. Hasil penelitian juga memberikan informasi bahwa kualitas citra, keberagaman data, dan kemampuan generalisasi model merupakan faktor penting yang perlu diperhatikan sebelum sistem diterapkan secara luas di lapangan.</i>
Saran	<i>Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran untuk penelitian selanjutnya adalah memperluas dan memperkaya dataset dengan citra yang berasal dari berbagai kondisi lingkungan, perangkat kamera, intensitas pencahayaan, dan lokasi pengambilan gambar agar kemampuan generalisasi model terhadap data dunia nyata dapat meningkat. Selain itu, perlu dilakukan eksplorasi terhadap teknik augmentasi yang lebih beragam maupun metode domain adaptation untuk</i>

	<i>mengurangi dampak perbedaan distribusi data antara dataset pelatihan dan dataset eksternal.</i> <i>Penelitian selanjutnya juga disarankan untuk meninjau kembali penggunaan kelas agregasi OtherDisease. Hasil pengujian menunjukkan bahwa kelas ini menjadi kelas yang paling sulit dikenali oleh model karena merupakan gabungan dari beberapa jenis penyakit yang memiliki karakteristik visual berbeda-beda. Penggabungan beberapa penyakit ke dalam satu label menyebabkan variasi intra-kelas menjadi sangat tinggi sehingga model kesulitan mempelajari pola yang konsisten. Oleh karena itu, akan lebih baik apabila setiap jenis penyakit diperlakukan sebagai kelas tersendiri atau kelas OtherDisease dihilangkan dari skema klasifikasi sehingga model dapat mempelajari karakteristik masing-masing penyakit secara lebih spesifik dan menghasilkan performa yang lebih baik.</i> <i>Selain itu, penelitian berikutnya dapat membandingkan lebih banyak arsitektur modern seperti EfficientNet, ConvNeXt, atau Vision Transformer (ViT), serta melakukan pengujian pada perangkat bergerak (mobile device) untuk mengevaluasi keseimbangan antara akurasi, kecepatan inferensi, dan kebutuhan sumber daya komputasi pada implementasi nyata.</i>
Daftar Pustaka	
Daftar Pustaka	<i>[1] U. P. Leiden, "Advancements in rice disease detection through convolutional neural networks," Scholarly Publications, 2024.</i> <i>[2] Y. I. Elhenawy, M. A. Nassef, and N. Zaki, "A deep learning approach for plant disease prediction using enhanced convolutional neural networks," Plants, vol. 13, no. 5, p. 705, 2024.</i> <i>[3] C. Researchers et al., "From Handcrafted Features to Vision Transformers: A Multi-Domain Survey of Image Classification Architectures, Datasets, and Applications," Preprints.org, 2026.</i> <i>[4] A. Authors et al., "Enhanced rice leaf disease classification via contour-driven segmentation and optimized deep transfer learning architectures," PLOS One, 2026.</i> <i>[5] S. Samanta et al., "Affordable Precision Agriculture: A Deployment-Oriented Review of Low-Cost, Low-Power Edge AI and TinyML for Resource-Constrained Environments," arXiv preprint arXiv:2603.15085, 2026.</i> <i>[6] I. Kurniawan, S. Sumijan, and G. W. Nurcahyo, "Penerapan metode YOLOv10 untuk deteksi penyakit pada tanaman kelapa sawit berdasarkan citra daun," Smart Comp: Jurnalnya Orang Pintar Komputer, vol. 14, no. 3, pp. 768–779, Jul. 2025.</i> <i>[7] V. Ayumi, "Klasifikasi penyakit tanaman berdasarkan analisis citra daun padi menggunakan metode SVM dan CLAHE," JSAI: Journal Scientific and Applied Informatics, vol. 7, no. 3, pp. 699–704, Nov. 2024.</i> <i>[8] B. M. Kusuma, T. I. Hermanto, and C. D. Lestari, "Optimasi dan Integrasi Convolutional Neural Network pada Aplikasi Android untuk Deteksi Penyakit Daun Padi," Jurnal INSTEK (Informatika Sains dan Teknologi), vol. 9, no. 2, pp. 251–xxx, Oct. 2024.</i>