

Laporan Kemajuan Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Ahmad Dhani Alfawwas (24031554096)
Anggota 1	Maria Agatha Metri Tetrajati (24031554189)
Anggota 2	Tara Tabriza Rachman (24031554107)
URL Github	https://github.com/apa-nyak/final-project-ml

Informasi Umum Proyek

Judul	Implementasi dan Analisis Komparatif MobileNetV3 dan MLP untuk Klasifikasi Penyakit Daun Padi
Topik	Pangan
Pilihan Rumusan Masalah	1.2 Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan
Revisi?	Ya / Tidak

Informasi Detil Dataset

Sumber dataset	Proses akuisisi data dalam proyek ini dilakukan dengan mengambil data sekunder dari repositori publik kaggle melalui URL https://www.kaggle.com/datasets/yusufmurtaza01/rice-leaf-diseases?select=rice_data_set_labels_plot.png dengan judul "RICE Leaf Diseases". Pemilihan dataset ini didasarkan pada relevansinya terhadap rumusan masalah pangan no 1.2 mengenai lambatnya adopsi teknologi dan transformasi digital, dimana proyek ini hadir sebagai solusi untuk menggantikan praktik budidaya dan pemantauan tanaman yang masih bersifat manual. Dataset ini memiliki struktur multimedia yang lengkap, yaitu citra daun padi dalam format .jpg serta berkas anotasi .txt standar YOLO (You Only Look Once) untuk 9 kelas kondisi tanaman. Sehingga dataset ini sangat mendukung implementasi dan analisis komparatif model MobileNet, CNN-MLP dalam proses klasifikasi penyakit daun padi.
Deskripsi awal fitur dataset	Dataset yang digunakan dalam proyek ini merupakan dataset multimedia yang mengintegrasikan dua komponen fitur utama untuk melatih model, yaitu fitur citra sebagai masukan (input) dan fitur anotasi sebagai target (label). Komponen utama pada dataset ini adalah atribut Image Data (image_file) yang bertipe data multimedia dalam format .jpg. Atribut ini menyimpan informasi visual mentah berupa nilai intensitas piksel yang merepresentasikan karakteristik biologis daun padi, seperti tekstur bercak penyakit, perubahan warna akibat infeksi patogen, serta pola kerusakan pada permukaan daun. Selain fitur citra ini, dataset juga menyertakan atribut Class Label (class_id) yang merupakan fitur target bertipe data kategorikal sebagai target klasifikasi. Atribut ini memetakan kondisi daun padi ke dalam sembilan kategori spesifik, yang mencakup satu kondisi sehat (Healthy) dan delapan jenis penyakit prevalen seperti Brown Spot, Leaf Blast, dan Bacterial Leaf Blight. Melalui atribut ini, model akan mampu mempelajari pola antar kategori penyakit secara akurat guna mendukung transformasi digital bagi petani.

	Namun, pada dataset ini satu gambar tidak selalu hanya memiliki satu objek penyakit saja. Dalam satu citra dapat ditemukan lebih dari satu area infeksi dengan label kelas yang berbeda maupun sama. Oleh karena itu, dataset ini dilengkapi atribut anotasi spasial berbasis bounding box pada format YOLO Detection yang terdiri dari lima nilai numerik, yaitu <i>class_id</i>, <i>x_center</i>, <i>y_center</i>, <i>width</i>, dan <i>height</i>. Seluruh koordinat tersebut telah dinormalisasi ke dalam rentang 0 hingga 1 terhadap ukuran gambar asli dan digunakan untuk menunjukkan lokasi area penyakit pada daun padi secara spesifik.
Detil-detil langkah pre-processing	Langkah Pre-processing yang kami lakukan dalam kemajuan proyek ini yaitu: 1. <i>Resize (Standarisasi Ukuran Citra)</i> Pada resize kami mengubah resolusi setiap gambar potongan daun menjadi matriks berukuran seragam, yaitu 224x224 piksel. Ukuran ini kami tetapkan karena standar spesifikasi dimensi input yang diwajibkan oleh arsitektur Transfer Learning modern seperti MobileNetV3. Menyeragamkan ukuran memastikan arsitektur layer dapat melakukan operasi komputasi matriks tanpa mengalami dimensi error. 2. <i>CLAHE (Contrast Limited Adaptive Histogram Equalization)</i> Pada tahap ini kami melakukan teknik manipulasi kontras dimana fotografi daun di lapangan (sawah) sering kali memiliki pencahayaan yang tidak merata dan ada daun yang terkena silau matahari, ada pula yang tertutup oleh bayangan daun lainnya. Citra pertama-tama diubah dari format warna RGB menjadi format LAB (lightness, A-Color, B-Color). Kemudian Algoritma CLAHE akan di aplikasikan pada channel L (Lightness). Tujuannya untuk meratakan pencahayaan lokal tanpa merusak atau mendistorsi warna asli daun dan warna penyakitnya sehingga channel A dan B tidak disentuh sama sekali. Hal ini menghasilkan visibilitas area infeksi atau bercak penyakit yang sebelumnya tersembunyi di area gelap akan menjadi jauh lebih jelas. 3. <i>Image Sharpening (Penajaman Fitur Tepi)</i> Langkah ini menerapkan filter konvolusi (High-Pass-Filter) menggunakan matriks kernel berukuran 3x3. Angka tengah yang tinggi yaitu 5 dengan sisi negatif yaitu -1 berfungsi untuk meningkatkan intensitas piksel tengah jika berada dari piksel sekitarnya. Hal ini bertujuan untuk mempertegas dan menajamkan garis tepi dari tekstur daun. Batas antara jaringan daun yang sehat dengan area pinggiran bercak penyakit akan menjadi sangat tajam. Sehingga arsitektur CNN sangat menyukai gambar dengan fitur tepi yang tegas karena akan mempermudah layer konvolusi awal dalam menangkap pola spasial. 4. <i>Cropping Adaptive (Pemotongan Adaptif)</i> Tujuan kami melakukan langkah ini adalah untuk mengubah gambar daun utuh beserta label YOLO menjadi gambar-gambar kecil yang fokus pada area penyakitnya saja. Beberapa langkah utama untuk melakukan cropping: a. <i>Sampling & Analisis Area</i> : Dimana kami mengambil 300 gambar sebagai sampel acak untuk menghitung statistik besar rata-rata area penyakit menggunakan Bounding Box. Kemudian, dibandingkan dengan luas daun secara keseluruhan. b. <i>Konversi Koordinat (YOLO ke Piksel)</i> : Fungsi dari <i>yolo_to_piksel</i> adalah membaca letak penyakit dari file .txt dan mengubah menjadi titik koordinat piksel asli pada gambar (titik X1, Y1 untuk sudut kiri atas, dan X2, Y2 untuk sudut kanan bawah). c. <i>Penyaringan Noise</i> : Pada tahap ini kami akan menghitung luas kotak penyakit. Jika ukurannya sangat kecil (rasio $< 0,0005$), maka gambar tersebut akan dilewati (skip). Hal ini untuk mencegah model kebingungan mempelajari noise, titik debu, atau kesalahan label.

	d. <i>Perluasan Dinamis (Adaptive Expand Ratio)</i> : Ditahap ini kami tidak memotong gambar pas-pasan dibatas penyakit, melainkan bingkai potongannya diperlebar secara masif. Jika rasio bbox area $< 0,0005$ maka akan diperbesar 3x lipat. kemudian, jika rasio bbox area $< 0,02$ maka akan diperbesar 2x lipat. Dan jika rasio bbox area $< 0,1$ maka akan diperbesar 1x lipat. hal ini agar model tetap bisa melihat tekstur “daun yang sehat” disekitarnya sebagai konteks. e. <i>Penyesuaian Batas (Clamping)</i> : Kami memastikan bingkai yang sudah diperlebar tadi tidak melewati batas keluar dari ukuran maksimal gambar asli dengan menggunakan fungsi min dan max. Lalu setelah kordinatnya aman, maka barulah gambar dipotong secara fisik (<code>image[y1:y2, x1:x2]</code>) dan disimpan ke dalam folder kelas masing-masing.
--	---

Kemajuan Pengerjaan

Teknik yang digunakan	Untuk mengatasi ketidakseimbangan kelas (<i>Imbalance Data</i>) yang Ekstream pada Dataset, kami mengimplementasikan strategi pembobotan kelas (<i>class weighting</i>) secara algoritmik untuk memitigasi dampak ketidakseimbangan distribusi data latih. Melalui fungsi <code>compute_class_weight</code> dengan parameter heuristik 'balanced', nilai bobot dikalkulasi secara proporsional berbanding terbalik dengan frekuensi kemunculan setiap label target. Nilai numerik yang dihasilkan kemudian dikonversi menjadi struktur data tensor pada ekosistem PyTorch dan diintegrasikan secara operasional ke dalam fungsi Cross-Entropy Loss. Integrasi ini memaksa arsitektur model untuk memberikan penalti komputasi yang jauh lebih masif saat terjadi kesalahan klasifikasi pada kelas minoritas, sehingga secara efektif mencegah model mengalami bias terhadap kelas yang mendominasi. Sebagai tahapan akhir konfigurasi, algoritma optimasi Adaptive Moment Estimation (Adam) diinisialisasi dengan laju pembelajaran (<i>learning rate</i>) sebesar 0,0001 untuk memastikan konvergensi pembaruan parameter model berjalan secara stabil.																	
	<table> <tr> <th>Kelas Penyakit Daun Padi</th> <th>Jumlah Sampel Asli</th> <th>Bobot Kelas (Class Weight)</th> </tr> <tr> <td>BacterialLeafBlight</td> <td>~1,500</td> <td>2.30x</td> </tr> <tr> <td>BrownSpot</td> <td>~10,500</td> <td>0.32x</td> </tr> <tr> <td>Healthy</td> <td>~10,500</td> <td>0.32x</td> </tr> <tr> <td>LeafSmud</td> <td>~5,500</td> <td>0.70x</td> </tr> <tr> <td>OtherDisease</td> <td>~5,500</td> <td>29.22x</td> </tr> </table> Interpretasi: Kelas minoritas (batang biru pendek) secara otomatis diberikan bobot penalti (batang merah) yang jauh lebih tinggi. Gambar 1. Penanganan Imbalance Data Metode klasifikasi pada penelitian ini menggunakan pendekatan Deep Learning berbasis Transfer Learning dengan arsitektur MobileNetV3 Large. MobileNetV3 digunakan sebagai model utama untuk ekstraksi fitur citra penyakit daun padi karena memiliki kompleksitas komputasi yang ringan, efisien, dan tetap mampu memberikan performa klasifikasi yang tinggi pada perangkat dengan sumber daya terbatas. Model pretrained yang telah dilatih pada dataset ImageNet dimanfaatkan untuk	Kelas Penyakit Daun Padi	Jumlah Sampel Asli	Bobot Kelas (Class Weight)	BacterialLeafBlight	~1,500	2.30x	BrownSpot	~10,500	0.32x	Healthy	~10,500	0.32x	LeafSmud	~5,500	0.70x	OtherDisease	~5,500
Kelas Penyakit Daun Padi	Jumlah Sampel Asli	Bobot Kelas (Class Weight)																
BacterialLeafBlight	~1,500	2.30x																
BrownSpot	~10,500	0.32x																
Healthy	~10,500	0.32x																
LeafSmud	~5,500	0.70x																
OtherDisease	~5,500	29.22x																

	mempercepat proses konvergensi dan meningkatkan kemampuan model dalam mengenali pola visual pada citra daun padi. Pada tahap implementasi, lapisan klasifikasi akhir bawaan MobileNetV3 diganti dengan fully connected layer baru yang disesuaikan dengan jumlah kelas pada dataset penelitian. Proses pelatihan dilakukan menggunakan optimizer Adam dengan fungsi loss Cross Entropy Loss yang dipadukan dengan class weighting untuk mengatasi ketidakseimbangan distribusi data antar kelas. Selain itu, diterapkan teknik augmentasi citra ringan seperti rotasi, horizontal flip, dan penyesuaian brightness untuk meningkatkan kemampuan generalisasi model terhadap variasi data citra.																																																							
Nilai metrik terakhir	Untuk memperoleh gambaran rinci mengenai performa model pada masing-masing kelas, dilakukan evaluasi menggunakan beberapa metrik pengukuran, yaitu precision, recall dan F1-score. Hasil evaluasi model pada pengujian yang telah dilakukan disajikan pada tabel berikut. <i>Tabel 1. Evaluasi Internal</i> <table><tr><th></th><th><i>Precision</i></th><th><i>Recall</i></th><th><i>F1-Score</i></th><th><i>Support</i></th></tr><tr><td><i>BacterialLeafBlight</i></td><td>0.98</td><td>1.00</td><td>0.99</td><td>395</td></tr><tr><td><i>BrownSpot</i></td><td>1.00</td><td>0.98</td><td>0.99</td><td>2641</td></tr><tr><td><i>Healthy</i></td><td>0.63</td><td>1.00</td><td>0.77</td><td>12</td></tr><tr><td><i>LeafSmut</i></td><td>1.00</td><td>1.00</td><td>1.00</td><td>1212</td></tr><tr><td><i>OtherDisease</i></td><td>0.65</td><td>0.94</td><td>0.77</td><td>54</td></tr><tr><td><i>accuracy</i></td><td></td><td></td><td>0.99</td><td>4314</td></tr><tr><td><i>macro avg</i></td><td>0.85</td><td>0.98</td><td>0.90</td><td>4314</td></tr><tr><td><i>weighted avg</i></td><td>0.99</td><td>0.99</td><td>0.99</td><td>4314</td></tr></table> Berdasarkan hasil pengujian yang telah dilakukan sesuai dengan Tabel 1. Evaluasi, model MobileNetV3 menghasilkan performa yang sangat tinggi dengan accuracy sebesar 99% dan weighted F1-score sebesar 99%. Nilai tersebut menunjukkan bahwa model mampu melakukan klasifikasi dengan sangat baik, bahkan pada sebagian besar kelas juga menunjukkan nilai yang mendekati sempurna. Namun, walaupun performa yang diperoleh menunjukkan hasil yang sangat baik, hasil tersebut tetap perlu dilakukan analisis lebih lanjut karena terdapat kemungkinan model mengalami overfitting atau data leakage. Hal ini bisa disebabkan dari proses cropping yang dilakukan sehingga menghasilkan beberapa citra dari sumber gambar yang sama. Oleh karena itu, dilakukan pengujian tambahan menggunakan dataset eksternal untuk memastikan apakah performa tinggi yang diperoleh benar-benar menunjukkan kemampuan model dalam mengenali pola penyakit atau hanya dipengaruhi oleh kemiripan data selama proses pelatihan. <i>Tabel 2. Evaluasi Eksternal</i> <table><tr><th></th><th><i>Precision</i></th><th><i>Recall</i></th><th><i>F1-Score</i></th><th><i>Support</i></th></tr><tr><td><i>BacterialLeafBlight</i></td><td>0.63</td><td>0.93</td><td>0.75</td><td>40</td></tr></table>		<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>	<i>BacterialLeafBlight</i>	0.98	1.00	0.99	395	<i>BrownSpot</i>	1.00	0.98	0.99	2641	<i>Healthy</i>	0.63	1.00	0.77	12	<i>LeafSmut</i>	1.00	1.00	1.00	1212	<i>OtherDisease</i>	0.65	0.94	0.77	54	<i>accuracy</i>			0.99	4314	<i>macro avg</i>	0.85	0.98	0.90	4314	<i>weighted avg</i>	0.99	0.99	0.99	4314		<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>	<i>BacterialLeafBlight</i>	0.63	0.93	0.75	40
		<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>																																																			
	<i>BacterialLeafBlight</i>	0.98	1.00	0.99	395																																																			
	<i>BrownSpot</i>	1.00	0.98	0.99	2641																																																			
	<i>Healthy</i>	0.63	1.00	0.77	12																																																			
	<i>LeafSmut</i>	1.00	1.00	1.00	1212																																																			
	<i>OtherDisease</i>	0.65	0.94	0.77	54																																																			
	<i>accuracy</i>			0.99	4314																																																			
	<i>macro avg</i>	0.85	0.98	0.90	4314																																																			
	<i>weighted avg</i>	0.99	0.99	0.99	4314																																																			
	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>																																																				
<i>BacterialLeafBlight</i>	0.63	0.93	0.75	40																																																				


<i>BrownSpot</i>	<i>0.69</i>	<i>0.82</i>	<i>0.75</i>	<i>40</i>
<i>LeafSmut</i>	<i>0.00</i>	<i>0.00</i>	<i>0.00</i>	<i>40</i>
<i>micro avg</i>	<i>0.65</i>	<i>0.58</i>	<i>0.62</i>	<i>120</i>
<i>macro avg</i>	<i>0.44</i>	<i>0.58</i>	<i>0.50</i>	<i>120</i>
<i>weighted avg</i>	<i>0.44</i>	<i>0.58</i>	<i>0.50</i>	<i>120</i>

Berdasarkan hasil evaluasi menggunakan dataset eksternal sesuai dengan Tabel 2. Evaluasi Eksternal, menunjukkan bahwa terdapat penurunan performa model yang cukup signifikan dibandingkan pengujian internal sebelumnya. Bahkan pada kelas LeafSmut diperoleh nilai precision, recall dan F1-score sebesar 0%, yang menunjukkan bahwa model tidak mampu mengenali kelas tersebut pada data eksternal. Secara keseluruhan macro average F1-score dan weight average F1-score diperoleh nilai sebesar 50%, hal ini menunjukkan bahwa performa model mengalami penurunan yang cukup besar ketika dihadapkan dengan data baru.

Perbedaan hasil antara pengujian internal dan eksternal mengindikasikan bahwa kemampuan generalisasi model masih terbatas. Hal ini dapat disebabkan oleh adanya perbedaan karakteristik antara data eksternal dan data pelatihan, seperti variasi pencahayaan, sudut pengambilan gambar, kualitas citra, maupun distribusi data. Di sisi lain, perbedaan performa yang cukup besar antara pengujian internal dan eksternal juga dapat mengarah pada dugaan adanya kemungkinan data leakage pada proses sebelumnya. Akibatnya model memperoleh performa yang sangat tinggi karena dapat mengenali pola visual yang serupa, namun mengalami penurunan saat diuji menggunakan data yang benar-benar berbeda

Visualisasi grafik
latih dan validasi

Berikut adalah grafik untuk training validation loss dan training validation accuracy model kami:




Gambar . Training Validation Loss

Berdasarkan grafik Training vs Validation Loss, model menunjukkan proses pembelajaran yang cepat dan stabil sejak awal pelatihan. Pada epoch pertama, training loss berada pada nilai sekitar 0,37 yang menunjukkan bahwa model masih memiliki tingkat kesalahan prediksi yang cukup tinggi. Namun pada epoch kedua nilai tersebut turun drastis menjadi sekitar 0,09, menandakan bahwa MobileNetV3

mampu dengan cepat mempelajari pola visual penyakit daun padi melalui proses transfer learning. Penurunan berlanjut hingga mencapai sekitar 0,01 pada epoch terakhir, yang menunjukkan bahwa model semakin baik dalam mengenali karakteristik setiap kelas pada data pelatihan.

Sementara itu, validation loss berada pada kisaran rendah sejak awal, yaitu sekitar 0,08 dan sempat turun hingga mendekati 0,02 pada beberapa epoch. Meskipun terjadi sedikit kenaikan pada epoch ketujuh hingga kesebelas hingga mendekati 0,10, nilainya kembali stabil pada epoch berikutnya di kisaran 0,03–0,05. Kondisi ini menunjukkan bahwa model masih memiliki kemampuan generalisasi yang baik dan tidak mengalami overfitting berat. Perbedaan nilai antara training loss dan validation loss yang relatif kecil juga mengindikasikan bahwa proses pelatihan berjalan stabil dan model mampu beradaptasi dengan baik terhadap data validasi.



Gambar . Training Validation Accuracy

Berdasarkan grafik Training vs Validation Accuracy, model menunjukkan peningkatan performa yang sangat cepat sejak awal pelatihan. Pada epoch pertama, training accuracy berada di sekitar 88%, yang menunjukkan bahwa model masih berada pada tahap awal pembelajaran pola penyakit daun padi. Namun pada epoch kedua akurasi pelatihan meningkat drastis menjadi sekitar 96%, menandakan bahwa MobileNetV3 mampu dengan cepat menyesuaikan parameter model terhadap karakteristik dataset melalui proses transfer learning. Setelah itu akurasi terus meningkat secara bertahap hingga mencapai sekitar 99,5% pada epoch terakhir, yang menunjukkan kemampuan model dalam mengenali pola citra pelatihan semakin optimal.

Sementara itu, validation accuracy sudah cukup tinggi sejak epoch pertama yaitu sekitar 96,7%, kemudian meningkat hingga berada pada rentang 98–99% pada epoch-epoch berikutnya. Meskipun terdapat sedikit fluktuasi, misalnya turun hingga sekitar 97,3% pada epoch ketujuh, performa validasi kembali meningkat pada epoch berikutnya dan mencapai nilai terbaik sekitar 98,8% pada epoch keempat belas. Perbedaan antara training accuracy dan validation accuracy yang relatif kecil menunjukkan bahwa model memiliki stabilitas pembelajaran yang baik dan tidak mengalami overfitting berat selama proses pelatihan.

Temuan

Berdasarkan proses pelatihan yang telah dilakukan, ditemukan beberapa kondisi khusus yang dapat memengaruhi performa model. Salah satu kondisi yang terlihat yaitu dataset memiliki ketidakseimbangan data yang cukup tinggi, dimana jumlah citra pada setiap kelas memiliki perbedaan yang signifikan. Hal ini berpotensi

	<i>menyebabkan model lebih dominan mempelajari pola pada kelas mayoritas sehingga kemampuan model dalam mengenali kelas minor dapat menurun.</i> <i>Di sisi lain, terdapat selisih performa yang cukup besar pada hasil pengujian internal dan eksternal. Hal ini mengarah pada dugaan adanya kemungkinan data leakage pada proses sebelumnya, dimana terdapat citra dengan karakteristik visual serupa tersebar pada data pelatihan dan validasi secara bersamaan. Akibatnya, model memperoleh performa yang sangat tinggi pada pengujian internal, namun mengalami penurunan performa yang cukup signifikan ketika diuji menggunakan data eksternal.</i> <i>Selain itu, pada pengujian eksternal juga ditemukan bahwa model mengalami kesulitan dalam mengenali beberapa kategori tertentu. Hal ini terlihat pada kelas LeafSmut yang memperoleh nilai precision, recall, dan F1-score sebesar 0, yang menunjukkan bahwa model tidak berhasil mengenali kelas tersebut pada data baru. Kondisi tersebut mengindikasikan bahwa model masih belum mampu mempelajari karakteristik visual beberapa kelas secara optimal.</i>
--	--